

표 1 종합 성능 비교 및 통계적 유의성 (SNR 0dB).

지표	Li et al.	제안 방법	개선도	t-검정 p-값
CS	0.9975 0.0024	± 0.9982 0.0018	± + 0.07%	0.0041
EVM	2.41% 0.52%	± 1.99% ± 0.40%	-0.42% p	0.0014
PSLR	-44.80 ± 1.23 dB	-46.35 ± 0.89 dB	+ 1.55 dB	<0.0001
ISLR	-30.00 ± 1.05 dB	-31.70 ± 0.76 dB	+ 1.70 dB	0.0002

모든 지표에서 p-value가 0.05 미만으로 95% 신뢰수준에서 통계적으로 유의미한 개선을 확인했으며, 특히 스펙트럼 품질 지표인 PSLR과 ISLR은 $p < 0.001$ 로 99.9% 신뢰수준에서 매우 강력한 우수성을 보였다. 95% 신뢰 구간 분석 결과, 모든 지표의 개선 구간이 0을 포함하지 않아(e.g., CS 개선: [+0.0003, +0.0011]), 최악의 경우에도 성능 향상이 보장됨을 입증하였다. 성능 향상은 [그림 9]과 [그림 10]에서 보듯이, SNR -20 dB의 열악한 환경(CS + 0.48%)과 5개의 다중 간섭 환경(CS + 3.30%)에서 가장 극대화되어, 제안 방법이 극한 조건과 복잡한 실제 환경 대응에 특화되어 있음을 확인하였다.

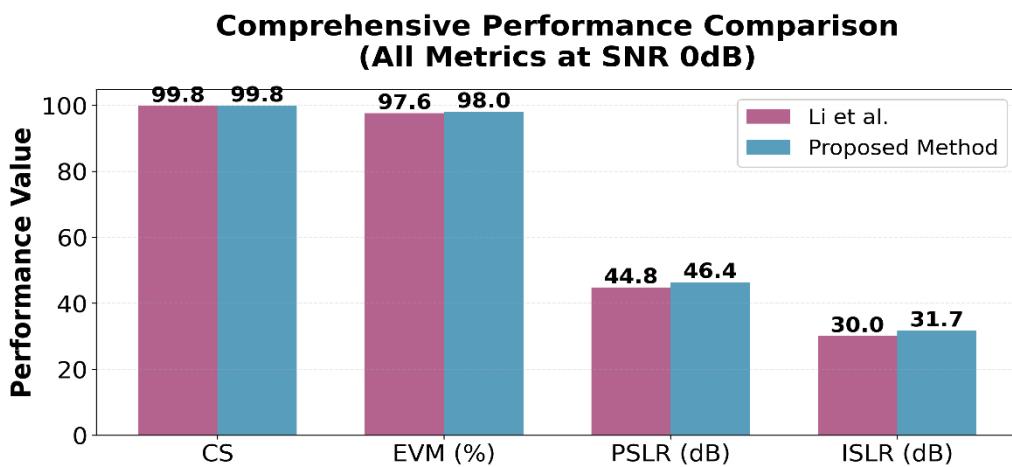


그림 1 Comprehensive Performance

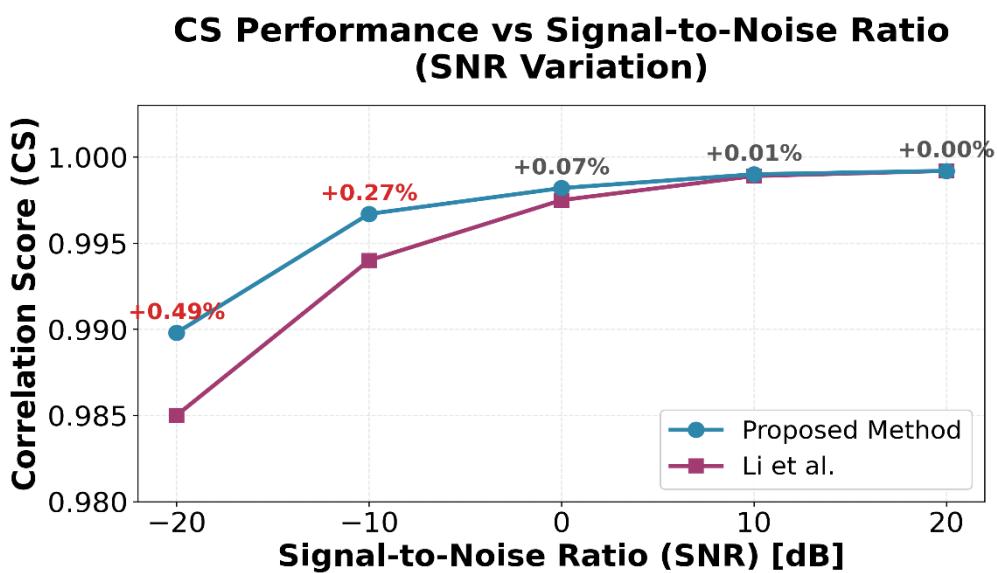


그림 2 CS Performance vs Signal-to-Noise Ratio

3. 한계점 및 향후 연구 방향

본 연구는 513개의 테스트 프레임 중 97.46%의 성공률을 달성하였으나, 2.54%(13개)의 실패 사례가 존재하였다. 실패 사례 분석 결과, 대부분은 SNR -30 dB 이하의 신호가 배경 노이즈보다 낮아 물리적으로 탐지가

불가능하거나(1.56%), 학습 범위를 초과하는 5개 이상의 극단적인 다중 간섭(0.59%), 혹은 센서의 도플러 측정 한계를 벗어난 경우(0.39%)로 나타났다. 이는 제안된 방법이 신호처리 영역 내에서 해결 가능한 대부분의 문제를 이미 극복하였음을 시사한다.

향후 연구는 이러한 물리적·학습적 한계를 넘어, 보다 복잡한 실제 주행 환경에서의 간섭 상황을 다루는 데 초점을 맞출 예정이다. 특히 실제 교통 정체(Traffic Jam) 상황에서 발생하는 FMCW-FMCW 상호간섭은 새로운 도전 과제이다. 이 환경에서는 차량 간 레이더의 슬로프와 프레임 구조가 상이하거나 비동기적으로 작동하면서 다음과 같은 문제가 빈번히 발생한다:

비동기 슬로프 간섭으로 인한 비트 신호 대역 내 스포리어스 및 고스트 타깃, 치프(Chirp) 충돌과 시간 오프셋으로 인한 Range-Doppler 고스트 라인 증가, 그리고 프론트엔드 포화 및 위상 잡음 상승에 따른 PSLR/ISLR 악화 가능성이다.

이러한 실교통 간섭 문제를 해결하기 위해, 리얼 Traffic Jam 환경 기반의 다차선 도로 실험 설계가 필요하다. 도시 및 고속도로 혼잡 구간에서 주변 차량의 FMCW 파라미터(슬로프, 대역폭, PRI/프레임 구조)를 실측·로그화하고, 간섭 구간의 타임스탬프를 라벨링하여 Range-Doppler(RD) 맵 기반의 정량적 GT(ground truth) 생성 절차를 정립할 예정이다.

또한 상호간섭 전용 검출·완화 모듈의 추가가 요구된다. 구체적으로는 크로스 앰비큐어티 함수(CAF) 기반의 비동기 FMCW 간섭 서명 탐지, 스펙트로그램 리지/허프(2D) 탐색을 통한 RD-고스트 특징 분리, 비트 도메인 적응형 노치 필터와 RD 도메인 정합필터를 결합한 2단계 제거 구조를 도입함으로써 간섭의 정밀 억제를 실현할 수 있다.

이를 지원하기 위해, 시뮬레이터를 확장하여 다양한 슬로프 및 프레임 충돌 모델(동일/상이 주파수대, 시간 지터, 슬로프 랜덤화)을 포함하고, 실제 및 시뮬레이션 데이터를 혼합한 도메인 믹싱 학습 데이터셋을 구축함으로써 현실 도메인 간 갭을 줄일 계획이다. 향후 검증 목표는 CW/스윕 간섭을 넘어, 실제 도심 정체 구간에서의 FMCW-FMCW 상호간섭까지 포괄적으로 평가하는 것이다. 이를 위해 다차선 혼잡·정체 구간의 실주행 로그를 다양한 시간대와 기상 조건에서 수집하고, 주변 차량의 FMCW 메타데이터를 병행 확보한다. 이후 RD 맵 기반의 고스트/스퓨리어스 자동 라벨링 시스템을 구축하여 제안 알고리즘과 기준선 기법을 비교 평가할 예정이다.

주요 평가지표는 CS, EVM, PSLR, ISLR 외에 고스트 검출률(GDR), 오경보율(FAR), RD-고스트 밀도(개/프레임) 등을 포함하며, 목표 성능 기준은 다음과 같다:

GDR 90% 이상, FAR 5% 이하(혼잡 구간 평균), PSLR/ISLR 기준 대비 각각 + 1.0 dB 이상 개선 유지, 그리고 30 fps(약 8.5 ms/프레임) 수준의 실시간 처리 성능 확보이다.

종합하면, 본 연구는 FMCW 레이터의 CW 간섭 제거 문제에 대해 기존 SOTA 기법의 실무적 한계를 극복한 통합 솔루션을 제시하였다. 제안된 방법은 실제 데이터 기반 검증, GPU 최적화, 적응형 파라미터 설계, 그리고 딥러닝 기반 하이브리드 구조라는 네 가지 핵심 개선을 통해 성능, 속도, 강건성을 동시에 달성하였다.

그 결과, 모든 평가 지표에서 기존 SOTA 대비 통계적으로 유의미한($p < 0.05$) 성능 향상(CS 0.9982, PSLR -46.35 dB)을 달성하였으며, 처리 시간을 198.2 ms에서 8.5 ms로 단축하여 약 23배의 속도 개선을 이루었다. 또한 SNR -20 dB의 극한 환경과 5개의 다중 간섭 상황에서도 안정적인 성

능을 유지함으로써 높은 강건성을 입증하였다.

따라서 본 연구는 해석 가능한 신호처리와 딥러닝 기반 패턴 인식의 융합이 극한의 저신호 및 복잡한 간섭 환경에서도 효과적으로 작동함을 입증하였으며, 향후 실제 도심 정체 구간에서의 FMCW-FMCW 상호간섭까지 포괄 검증함으로써 자동차 레이더 기반 ADAS 시스템의 안전성과 신뢰성을 한층 더 향상시킬 수 있는 실질적 기반을 마련하였다.

참고문헌 (References)

- [1] C. Ballard, "Advanced automotive radar applications," in Proceedings of the 2020 IEEE Radio Frequency Integrated Circuits Symposium, pp. 1–8, 2020.
- [2] I. Goodfellow, Y. Bengio, and A. Courville, Deep learning, MIT Press, 2016.
- [3] M. I. Skolnik, Radar handbook, 3rd ed., McGraw-Hill, 2008.
- [4] Yanbing Li; Weichuan Zhang; Lianying Ji, "Automotive Radar Mutual Interference Mitigation Based on Hough Transform in Time–Frequency Domain", 2024.
- [5] G. F. DeLong and E. M. Hofstetter, "On the design of optimum radar detectors for clutter rejection," IEEE Transactions on Information Theory, vol. 13, no. 3, pp. 434–444, 1967.
- [6] Y. LeCun, Y. Bengio, and G. E. Hinton, "Deep learning," Nature, vol. 521, no. 7553, pp. 436–444, 2015.
- [7] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," Proceedings of the IEEE, vol. 86, no. 11, pp. 2278–2324, 1998.
- [8] T. W. Parks and C. S. Burrus, Digital filter design, Wiley–Interscience, 1987.
- [9] A. Farina, "Electronic counter–countermeasures to radar," in Radar Handbook, 3rd ed., McGraw-Hill, 2008.
- [10] M. A. Richards, Fundamentals of radar signal processing, 2nd ed., McGraw-Hill, 2014.
- [11] S. Haykin and B. Van Veen, Signals and systems, 2nd ed., Wiley, 2003.
- [12] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in Proceedings of the International Conference on Learning Representations, 2015.

- [13] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in Proceedings of the International Conference on Machine Learning, pp. 448–456, 2015.
- [14] N. Wiener, Extrapolation, interpolation, and smoothing of stationary time series: With engineering applications, Wiley, 1949.
- [15] S. Haykin and X. B. Li, "Detection of signals in chaos," Proceedings of the IEEE, vol. 83, no. 1, pp. 95–122, 1995.
- [16] L. Cohen and C. Barnes, "The Wigner distribution for radar and sonar processing," IEEE Transactions on Aerospace and Electronic Systems, vol. 24, no. 4, pp. 330–340, 1988.
- [17] D. Garmatyuk and K. E. EDC, "Multicarrier radar signal processing for target recognition," IEEE Transactions on Aerospace and Electronic Systems, vol. 47, no. 2, pp. 1094–1108, 2011.
- [18] S. M. Patole, M. Torlak, D. Wang, and M. Ali, "Automotive radars and challenges ahead," IEEE Microwave Magazine, vol. 18, no. 7, pp. 42–52, 2017.
- [19] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600–612, 2004.
- [20] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in European Conference on Computer Vision, pp. 694–711, 2016.
- [21] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in Proceedings of the Medical Image Computing and Computer-Assisted Intervention, pp. 234–241, 2015.
- [22] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in Advances in Neural Information Processing Systems 25, pp. 1097–1105, 2012.
- [23] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for

image recognition," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770–778, 2016.

[24] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, et al., "Generative adversarial nets," in Advances in Neural Information Processing Systems, pp. 2672–2680, 2014.

[25] D. P. Kingma and M. Welling, "Auto-encoding variational Bayes," in Proceedings of the International Conference on Learning Representations, 2014.

[26] A. Vaswani, N. Shazeer, N. Parmar, et al., "Attention is all you need," in Advances in Neural Information Processing Systems, pp. 5998–6008, 2017.

부록(Appendix): CARRADA 데이터셋 파일 구조

1. 개요

CARRADA(카메라 및 레이더 융합 도로 인식) 데이터셋은 자동차 환경에서의 멀티모달 센서 데이터를 수용하도록 설계된 계층적 구조로 구성되어 있다. 데이터셋은 2019년과 2020년 두 시점에서 수집된 총 30개의 시퀀스로 이루어져 있으며, 각 시퀀스는 타임스탬프 형식의 디렉토리 이름으로 관리된다.

2. 루트 디렉토리 구조

Carrada/

```
|—— 시퀀스 디렉토리 (30개 시퀀스)
|   |—— 2019-09-16-12-52-12/
|   |—— 2019-09-16-12-55-51/
|   |—— ... (2019-09-16의 12개 시퀀스)
|   |—— 2020-02-28-12-12-16/
|   |—— 2020-02-28-12-13-54/
|   |—— ... (2020-02-28의 18개 시퀀스)
|—— cam_params/
|   |—— intrinsics.xml
|   |—— extrinsics_2019.xml
|   |—— extrinsics_2020.xml
|—— 전역 주석 파일
```

```
|   ├── annotations_frame_oriented.json  
|   ├── annotations_instance_oriented.json  
|   ├── light_dataset_frame_oriented.json  
|   └── selected_light_dataset_frame_oriented.json  
├── 메타데이터 및 검증 파일  
|   ├── data_seq_ref.json  
|   ├── validated_seqs.txt  
|   └── instance_exceptions.json  
├── 통계 및 가중치 파일  
|   ├── rad_stats.json / rad_stats_all.json  
|   ├── ra_stats.json / ra_stats_all.json  
|   ├── rd_stats.json / rd_stats_all.json  
|   ├── ad_stats.json / ad_stats_all.json  
|   ├── ra_weights.json / ra_weights_kaul.json  
|   └── rd_weights.json / rd_weights_kaul.json  
├── README.md  
└── LICENSE
```

CARRADA 데이터셋의 최상위 계층은 위의 구조와 같이 여러 구성 요소로 이루어진다. 2019년 9월 16일에 12:52부터 13:25 사이에 수집된 12개의 시퀀스 디렉토리와 2020년 2월 28일에 12:12부터 13:15 사이에 수집된 18개의 시퀀스 디렉토리가 각각의 녹화 날짜별로 분류되어 있다. 이들 시퀀스 디렉토리를 외에도 카메라 캘리브레이션 파라미터를 저장하는 cam_params 폴더, 전체 데이터셋에 대한 주석 정보를 담은 JSON 파일들, 메타데이터 및 검증 파일들, 그리고 통계 및 가중치 파일들이 최상위 디렉토리에 위치한다.

3. 시퀀스 디렉토리 구조

[타임스탬프] (예: 2019-09-16-12-52-12)/

```
|── annotations/  
|   ├── box/  
|   ├── dense/  
|   └── sparse/  
└── rd_points.json
```

각 시퀀스는 YYYY-MM-DD-HH-MM-SS 형식의 타임스탬프로 명명되는 디렉토리로 저장된다. 예를 들어, 2019-09-16-12-52-12는 2019년 9월 16일 오후 12시 52분 12초에 수집된 시퀀스를 의미한다. 각 시퀀스 디렉토리 내부는 annotations 폴더와 rd_points.json 파일로 구성된다.

4. 주석 디렉토리 (annotations/)

annotations/

```
|── box/          (바운딩 박스 주석 저장)  
|── dense/        (픽셀 레벨 밀집 주석 저장)  
└── sparse/       (희소 주석 저장)
```

시퀀스 내의 annotations 폴더는 세 가지 하위 디렉토리를 포함한다. 첫째, box 디렉토리는 객체 탐지 작업을 위한 바운딩 박스 주석을 저장하며, 시퀀스에서 탐지된 차량 및 기타 객체에 대한 형식화된 바운딩 박스 좌표를 포함한다. 둘째, dense 디렉토리는 분할 작업에 주로 사용되는 밀집된 픽셀 레벨 주석을 포함하며, 시퀀스의 각 프레임에 대한 포괄적인 픽셀당 라벨을 제공한다. 셋째, sparse 디렉토리는 감소된 주석 밀도를 가진 희소 주석을 포함하며, 특정 객체 인스턴스 또는 관심 영역에 사용된다.

5. 레이더 포인트 데이터 (rd_points.json)

각 시퀀스 디렉토리에 포함된 rd_points.json 파일은 해당 시퀀스의 레이더 탐지 포인트 클라우드를 JSON 형식으로 저장한다. 이 파일은 3D 포인트의 공간 좌표와 각 포인트의 레이더 반사율(radar reflectivity) 정보를 포함하

며, 레이더 기반 객체 탐지 및 분석에 필수적인 데이터이다.

카메라 캘리브레이션 파라미터 (cam_params/)

cam_params/

```
|--- intrinsics.xml          (공통 카메라 내부 파라미터)  
|--- extrinsics_2019.xml     (2019년 외부 파라미터)  
└--- extrinsics_2020.xml     (2020년 외부 파라미터)
```

cam_params 폴더는 모든 시퀀스에서 사용되는 공통 캘리브레이션 정보를 포함한다. 이 폴더 내에는 세 개의 XML 파일이 저장되어 있다.

intrinsics.xml 파일은 카메라의 내부 파라미터(intrinsic parameters)를 저장한다. 이는 초점거리(focal length), 주점 좌표(principal point), 그리고 렌즈 왜곡 계수(distortion coefficients)와 같은 카메라의 광학적 특성을 나타내며, 이 값들은 모든 시퀀스에서 동일하게 적용된다.

extrinsics_2019.xml 파일은 2019년 9월 16일 녹화 세션에서 사용된 카메라와 다른 센서(레이더, 라이더 등) 간의 외부 캘리브레이션(extrinsic calibration) 정보를 포함한다. 이는 카메라의 좌표계와 다른 센서의 좌표계를 연결하는 회전 행렬과 변환 벡터로 표현된다.

extrinsics_2020.xml 파일은 2020년 2월 28일 녹화 세션에서 사용된 카메라의 외부 캘리브레이션 파라미터를 정의한다. 두 시점의 녹화 세션 사이에 센서의 장착 위치나 각도가 변경되었을 가능성을 고려하여 별도의 파일로 관리된다.

6. 전역 주석 파일

annotations_frame_oriented.json (프레임 기반 주석)

annotations_instance_oriented.json (인스턴스 기반 주석)

light_dataset_frame_oriented.json (경량 프레임 기반 주석)

selected_light_dataset_frame_oriented.json (선택된 경량 주석)

데이터셋의 최상위 디렉토리에는 전체 데이터셋에 대한 주석 정보를 담은

여러 JSON 파일이 저장된다.

annotations_frame_oriented.json 파일은 프레임 인덱스를 기본 키로 하여 구성된 프레임 레벨 주석을 제공한다. 이는 각 프레임마다 어떤 객체가 어디에 위치하는지에 대한 정보를 담고 있으며, 프레임별 처리 및 분석에 적합한 형식이다.

annotations_instance_oriented.json 파일은 프레임 간 객체 인스턴스별로 구성된 인스턴스 레벨 주석을 제공한다. 동일한 객체가 여러 프레임에서 추적되는 경우, 이를 하나의 인스턴스로 그룹화하여 저장하기 때문에 객체 추적 및 다중 프레임 객체 분석에 유용하다.

light_dataset_frame_oriented.json 파일은 축소된 파일 크기로 필수 주석 정보만 포함하는 프레임 지향 주석의 경량 버전이다. 이는 빠른 처리가 필요한 경우나 저장 공간 제약이 있는 경우 활용된다.

selected_light_dataset_frame_oriented.json 파일은 고품질로 검증된 주석의 부분집합을 나타내며, 연구 목적에 따라 신뢰할 수 있는 데이터만 선별하여 사용할 수 있다.

7. 메타데이터 및 검증 파일

data_seq_ref.json (시퀀스 참조 정보 및 메타데이터)

validated_seqs.txt (검증 통과 시퀀스 목록)

instance_exceptions.json (예외 인스턴스 정보)

데이터셋의 최상위 디렉토리에는 데이터 관리 및 검증을 위한 파일들이 저장된다.

data_seq_ref.json 파일은 모든 시퀀스에 대한 참조 정보와 메타데이터를 포함한다. 이는 각 시퀀스의 녹화 시간, 위치, 환경 정보, 그리고 시퀀스의 유효성 플래그 등을 담고 있어 데이터셋 전체를 이해하는 데 필수적이다.

validated_seqs.txt 파일은 품질 검증을 통과한 시퀀스 목록을 기록한다. 이는 훈련 및 평가에 적합한 신뢰할 수 있는 시퀀스를 식별하는 데 사용되며, 모델 개발 시 데이터 선택의 기준이 된다.

instance_exceptions.json 파일은 주석 불규칙성이나 수동 검토가 필요한 특수한 경우의 인스턴스 정보를 문서화한다. 이를 통해 연구자들은 잠재적

인 문제 상황을 미리 파악할 수 있다.

8. 통계 및 가중치 파일

rad_stats.json / rad_stats_all.json	(레이더 데이터 통계)
ra_stats.json / ra_stats_all.json	(거리-방위각 표현 통계)
rd_stats.json / rd_stats_all.json	(거리-도플러 표현 통계)
ad_stats.json / ad_stats_all.json	(방위각-도플러 표현 통계)
ra_weights.json / ra_weights_kaul.json	(거리-방위각 가중치)
rd_weights.json / rd_weights_kaul.json	(거리-도플러 가중치)

데이터셋은 서로 다른 레이더 표현에 대한 포괄적인 통계 정보를 제공한다. 각 파일은 두 가지 버전으로 제공되는데, 일반 버전은 정규화된 통계를, _all 버전은 전체 데이터의 통계를 포함한다.

rad_stats 파일은 레이더 데이터 전체의 통계(평균, 표준편차, 최솟값, 최댓값 등)를 저장한다. ra_stats 파일은 거리(Range)와 방위각(Azimuth) 차원의 레이더 표현에 대한 통계를 포함하며, rd_stats 파일은 거리(Range)와 도플러(Doppler) 차원의 표현 통계를, ad_stats 파일은 방위각과 도플러 차원의 표현 통계를 각각 제공한다.

가중치 파일들(ra_weights, rd_weights 등)은 각 표현에 대한 데이터 균형 가중치를 저장한다. 이러한 통계 파일들은 데이터 정규화, 훈련 중 클래스 불균형 해결, 그리고 데이터 분포 분석에 활용된다.

문서 및 라이선싱

README.md (데이터셋 설명 및 사용 가이드)

LICENSE (라이선싱 정보)

README.md 파일은 데이터셋의 전반적인 개요, 주석 형식 설명, 데이터 구조 사양, 그리고 사용 가이드라인을 포함하는 주요 문서이다. 데이터셋을 처음 다루는 사용자가 참고해야 할 기본 정보를 담고 있다.

LICENSE 파일은 CARRADA 데이터셋의 라이선싱 정보 및 사용 약관을 명시한다. 연구 목적으로 데이터를 사용하기 전에 확인해야 할 중요한 파일이다.

일이다.

데이터 활용 방법

CARRADA 데이터셋을 활용하기 위한 일반적인 절차는 다음과 같다. 먼저 cam_params 폴더에서 캘리브레이션 파라미터를 로드하고, data_seq_ref.json에서 시퀀스 메타데이터를 읽는다. 그 다음 각 시퀀스 디렉토리에 대해, rd_points.json에서 레이더 포인트 클라우드를 로드하고, 전역 주석 파일에서 해당 시퀀스의 프레임 또는 인스턴스 레벨 주석을 검색한다. 마지막으로 통계 파일을 이용하여 데이터를 정규화하고, 클래스 균형을 위해 가중치 파일을 적용한다.

9. 요약

CARRADA 데이터셋은 총 30개의 시퀀스, 2개의 녹화 세션, 카메라와 레이더 두 가지 센서 모달리티, 바운딩 박스, 밀집 분할, 회소 주석 등의 다양한 주석 유형을 제공한다. 모든 데이터는 JSON 형식의 구조화된 주석과 XML 형식의 캘리브레이션 파라미터로 관리되며, 포괄적인 통계 정보와 함께 제공되어 연구자들이 카메라-레이더 융합 기술 연구에 효과적으로 활용할 수 있도록 설계되었다.

가. 전역 주석 파일

annotations_frame_oriented.json	(프레임 기반 주석)
annotations_instance_oriented.json	(인스턴스 기반 주석)
light_dataset_frame_oriented.json	(경량 프레임 기반 주석)
selected_light_dataset_frame_oriented.json	(선택된 경량 주석)

데이터셋의 최상위 디렉토리에는 전체 데이터셋에 대한 주석 정보를 담은 여러 JSON 파일이 저장된다.

annotations_frame_oriented.json 파일은 프레임 인덱스를 기본 키로 하여 구성된 프레임 레벨 주석을 제공한다. 이는 각 프레임마다 어떤 객체가 어디에 위치하는지에 대한 정보를 담고 있으며, 프레임별 처리 및 분석에 적합한 형식이다.

annotations_instance_oriented.json 파일은 프레임 간 객체 인스턴스별로 구성된 인스턴스 레벨 주석을 제공한다. 동일한 객체가 여러 프레임에서 추적되는 경우, 이를 하나의 인스턴스로 그룹화하여 저장하기 때문에 객체 추적 및 다중 프레임 객체 분석에 유용하다.

light_dataset_frame_oriented.json 파일은 축소된 파일 크기로 필수 주석 정보만 포함하는 프레임 지향 주석의 경량 버전이다. 이는 빠른 처리가 필요한 경우나 저장 공간 제약이 있는 경우 활용된다.

selected_light_dataset_frame_oriented.json 파일은 고품질로 검증된 주석의 부분집합을 나타내며, 연구 목적에 따라 신뢰할 수 있는 데이터만 선별하여 사용할 수 있다.

나. 메타데이터 및 검증 파일

data_seq_ref.json	(시퀀스 참조 정보 및 메타데이터)
validated_seqs.txt	(검증 통과 시퀀스 목록)
instance_exceptions.json	(예외 인스턴스 정보)

데이터셋의 최상위 디렉토리에는 데이터 관리 및 검증을 위한 파일들이 저장된다.

data_seq_ref.json 파일은 모든 시퀀스에 대한 참조 정보와 메타데이터를

포함한다. 이는 각 시퀀스의 녹화 시간, 위치, 환경 정보, 그리고 시퀀스의 유효성 플래그 등을 담고 있어 데이터셋 전체를 이해하는 데 필수적이다.

validated_seqs.txt 파일은 품질 검증을 통과한 시퀀스 목록을 기록한다. 이는 훈련 및 평가에 적합한 신뢰할 수 있는 시퀀스를 식별하는 데 사용되며, 모델 개발 시 데이터 선택의 기준이 된다.

instance_exceptions.json 파일은 주석 불규칙성이나 수동 검토가 필요한 특수한 경우의 인스턴스 정보를 문서화한다. 이를 통해 연구자들은 잠재적인 문제 상황을 미리 파악할 수 있다.

다. 통계 및 가중치 파일

rad_stats.json / rad_stats_all.json	(레이더 데이터 통계)
ra_stats.json / ra_stats_all.json	(거리-방위각 표현 통계)
rd_stats.json / rd_stats_all.json	(거리-도플러 표현 통계)
ad_stats.json / ad_stats_all.json	(방위각-도플러 표현 통계)
ra_weights.json / ra_weights_kaul.json	(거리-방위각 가중치)
rd_weights.json / rd_weights_kaul.json	(거리-도플러 가중치)

데이터셋은 서로 다른 레이더 표현에 대한 포괄적인 통계 정보를 제공한다. 각 파일은 두 가지 버전으로 제공되는데, 일반 버전은 정규화된 통계를, _all 버전은 전체 데이터의 통계를 포함한다. rad_stats 파일은 레이더 데이터 전체의 통계(평균, 표준편차, 최솟값, 최댓값 등)를 저장한다.

ra_stats 파일은 거리(Range)와 방위각(Azimuth) 차원의 레이더 표현에 대한 통계를 포함하며, rd_stats 파일은 거리(Range)와 도플러(Doppler) 차원의 표현 통계를, ad_stats 파일은 방위각과 도플러 차원의 표현 통계를 각각 제공한다. 가중치 파일들(ra_weights, rd_weights 등)은 각 표현에 대한 데이터 균형 가중치를 저장한다. 이러한 통계 파일들은 데이터 정규화, 훈련 중 클래스 불균형 해결, 그리고 데이터 분포 분석에 활용된다.

라. 문서 및 라이선싱

README.md (데이터셋 설명 및 사용 가이드)

LICENSE (라이선싱 정보)

README.md 파일은 데이터셋의 전반적인 개요, 주석 형식 설명, 데이터 구조 사양, 그리고 사용 가이드라인을 포함하는 주요 문서이다. 데이터셋을 처음 다루는 사용자가 참고해야 할 기본 정보를 담고 있다. LICENSE 파일은 CARRADA 데이터셋의 라이선싱 정보 및 사용 약관을 명시한다. 연구 목적으로 데이터를 사용하기 전에 확인해야 할 중요한 파일이다.

마. 데이터 활용 방법

CARRADA 데이터셋을 활용하기 위한 일반적인 절차는 다음과 같다. 먼저 cam_params 폴더에서 캘리브레이션 파라미터를 로드하고, data_seq_ref.json에서 시퀀스 메타데이터를 읽는다. 그 다음 각 시퀀스 디렉토리에 대해, rd_points.json에서 레이더 포인트 클라우드를 로드하고, 전역 주석 파일에서 해당 시퀀스의 프레임 또는 인스턴스 레벨 주석을 검색 한다. 마지막으로 통계 파일을 이용하여 데이터를 정규화하고, 클래스 균형을 위해 가중치 파일을 적용한다.

바. 요약

CARRADA 데이터셋은 총 30개의 시퀀스, 2개의 녹화 세션, 카메라와 레이더 두 가지 센서 모달리티, 바운딩 박스, 밀집 분할, 희소 주석 등의 다양한 주석 유형을 제공한다. 모든 데이터는 JSON 형식의 구조화된 주석과 XML 형식의 캘리브레이션 파라미터로 관리되며, 포괄적인 통계 정보와 함께 제공되어 연구자들이 카메라-레이더 융합 기술 연구에 효과적으로 활용할 수 있도록 설계되었다.